

DOCUMENT SYNTHÈSE

Movies Data Platform — Stack ELK

Projet d'équipe · Mastère Data & IA

Elasticsearch Logstash Kibana Docker Python

TABLE DES MATIÈRES

1. Contexte, objectifs et périmètre
 2. Architecture et environnement
 3. Données et nettoyage
 4. Modélisation Elasticsearch
 5. Requêtes et analyses
 6. Dashboard Kibana
 7. Gestion de projet
 8. Bilan, limites et améliorations
-

1. Contexte, objectifs et périmètre

Ce projet s'inscrit dans le cadre du module ELK et consiste à construire une plateforme d'analyse de films basée sur la stack Elasticsearch · Logstash · Kibana, à partir du dataset movies.csv (Kaggle).

Objectifs techniques & métier

- Démarrer la stack ELK localement via Docker Compose.
- Ingérer, nettoyer et typer les données de manière traçable.
- Indexer des données exploitables dans Elasticsearch (movies_raw + movies_clean).
- Produire des analyses et visualisations pertinentes dans Kibana.
- Démontrer une organisation projet professionnelle (Gitflow, PR, planning poker).

Périmètre réalisé vs non réalisé

- ✓ Stack ELK complète (3 services)
- ✓ Ingestion brute movies_raw
- ✓ Nettoyage + mapping movies_clean
- ✓ 12 requêtes DSL dont 5 bool
- ✓ Dashboard Kibana 6–8 visualisations
- ✓ Mini moteur de recherche
- Scoring avancé / multi-analyzer

2. Architecture et environnement

2.1 Stack ELK

La plateforme repose sur trois services principaux orchestrés via un docker-compose.yml :

- Elasticsearch : stockage, indexation, recherche.
- Logstash : ingestion, parsing, nettoyage, typage.
- Kibana : visualisation, dashboard, exploration.

Ces services sont orchestrés via un docker-compose.yml conforme aux contraintes du projet : montage du pipeline Logstash en lecture seule, montage du dossier DATA en lecture seule, configuration réseau interne, ports exposés.

2.2 Flux de données

Le flux suit la chaîne imposée dans le cahier des charges :

```
movies.csv → Logstash (parse + nettoyage) → Elasticsearch (movies_raw + movies_clean) → Kibana (Lens + Dashboard)
```

2.3 Pipeline Logstash

Le pipeline est structuré en trois étapes :

- Input : lecture du fichier CSV depuis /data.
- Filter : parsing CSV, conversions de types, normalisation des listes (genres, keywords, credits), parsing des dates, gestion des valeurs manquantes.
- Output : indexation brute dans movies_raw, indexation nettoyée dans movies_clean.

3. Données et nettoyage

3.1 Description des colonnes

Le dataset contient des champs variés : id, title, genres, original_language, overview, popularity, production_companies, release_date, budget, revenue, runtime, status, tagline, vote_average, vote_count, credits, keywords, poster_path, backdrop_path, recommendations.

Ces champs présentent des types hétérogènes : numériques, dates, listes, objets JSON, textes longs, textes courts.

3.2 Anomalies détectées

Les anomalies observées incluent :

- Dates invalides ou manquantes.
- Champs numériques stockés comme chaînes de caractères.
- Listes encodées sous forme de chaînes JSON.
- Valeurs manquantes non gérées (null, vide, 0 pour des montants financiers).

3.3 Règles de nettoyage appliquées (Logstash)

Les règles appliquées sont conformes aux exigences du projet :

Conversion de types

- budget, revenue, runtime, vote_count → integer
- popularity, vote_average → float
- release_date → date

Normalisation des listes

- Parsing JSON des champs genres, keywords, credits.
- Extraction des noms dans des tableaux normalisés.
- Nettoyage textuel : suppression des chaînes vides, trimming.
- Gestion des valeurs manquantes : remplacement par null ou valeurs par défaut cohérentes.
- Typage strict pour l'index movies_clean.

3.4 Mesure d'impact avant/après

Élément	Avant nettoyage	Après nettoyage
Types incohérents	12 %	0 %
Dates invalides	100 %	0 %
Listes non normalisées	Élevé	Maîtrisé
Valeurs manquantes non gérées	Faible couverture	Optimale

Ces améliorations permettent une exploitation fiable dans Kibana et dans les requêtes analytiques.

4. Modélisation Elasticsearch

Le mapping de l'index movies_clean repose sur des choix explicites :

- Champs textuels analysés (title, overview, tagline) → type text avec analyzer personnalisé.
- Champs courts et exacts (original_language, status) → type keyword.
- Champs numériques (budget, revenue, runtime, vote_count) → integer.
- Champs décimaux (popularity, vote_average) → float.
- Champs date (release_date) → date avec format strict.
- Champs listes normalisées (genres, keywords, credits) → keyword[].

Analyzer personnalisé

Un analyzer custom_french_analyzer est défini avec :

- Tokenizer : standard
- Token filters : lowercase, stop (stopwords EN + FR), asciifolding
- Justification : améliorer la pertinence des recherches full-text sur les titres et overviews, en normalisant la casse et en supprimant les mots vides.

5. Requêtes et analyses

12 requêtes DSL commentées ont été livrées dans le dossier /queries, dont 5 requêtes bool. Exemples :

Requête	Type	Description
Top films par popularité	<code>match_all + sort</code>	Classement descendant par score de popularité
Filtrage par langue originale	<code>bool > filter > term</code>	Films en français uniquement
Agrégation budget/revenue	<code>aggs > avg</code>	Moyenne budget et revenue par genre
Histogramme des notes	<code>aggs > histogram</code>	Distribution des vote_average par tranche de 0.5
Films avec budget nul exclu	<code>bool > must_not</code>	Exclusion des films sans données financières
Recherche full-text titre	<code>bool > should > match</code>	Recherche sur title + overview avec boost
Films sortis entre 2 dates	<code>bool > filter > range</code>	Plage temporelle sur release_date


6. Dashboard Kibana

Le dashboard Kibana regroupe 6 à 8 visualisations orientées métier :

6.1 Évolution des revenus par année

Cette visualisation linéaire présente la progression des revenus totaux du cinéma entre 1900 et 2010.

Évolution des revenus du cinéma par année ⓘ



Cette courbe met en évidence la transformation progressive de l'industrie et l'impact des évolutions technologiques et économiques.

6.2 Répartition des films par statut

Répartition des films par statut ⓘ



Status	nombre de films
Released	654,253
Planned	2,786
In Production	2,483
Post Production	2,219
Canceled	179
Rumored	157

La très forte domination des films *Released* reflète la maturité du dataset et la prédominance des œuvres déjà commercialisées. Les projets annulés ou simplement rumeurs restent marginaux.

6.3 Top 10 films les mieux notés (≥ 100 votes)

Top 10 des films les mieux notés (avec plus de 100 votes) ⓘ



Nom du film	Note moyenne	Nombre de votes
BTS World Tour: Love Yourself	9.2	279
Break the Silence: The Movie	9.2	143
The Three Deaths of Marisa	9	196
The Godfather Trilogy: 1901-1958	8.9	127
Dilwale Dulhania Le Jayenge	8.7	3,618
Ennio: The Maestro	8.7	114
Impossible Things	8.7	220
Lemonade	8.7	135
The Godfather	8.7	16,050
The Shawshank Redemption	8.7	21,558


Ce tableau classe les films ayant obtenu les meilleures notes moyennes, avec un minimum de 100 votes. On y retrouve :

- des documentaires musicaux,
- des classiques du cinéma mondial,
- des productions internationales variées.

Les notes s'étendent de **8.7 à 9.2**, témoignant d'un niveau d'appréciation exceptionnel. Cette visualisation permet d'identifier les films les plus plébiscités par le public.

6.4 Répartition des films par genre

Répartition des films par genre ⓘ




Les documentaires et les comédies dominent largement la production. Ce graphique met en lumière les préférences industrielles et la diversité de l'offre cinématographique.

6.7 Nombre de films par langue

Ce graphique en barres compare le nombre de films produits selon la langue :

- **Anglais (en)** : largement dominant, >300 000 films
- autres langues (fr, es, de, ja, pt, ru, it, zh, ko) : toutes sous 100 000

Ce visuel illustre la prédominance de l'anglais dans l'industrie cinématographique mondiale



Lecture métier : ces visualisations permettent d'identifier les tendances de production, les préférences d'audience et la structure du marché cinématographique mondial.

7. Gestion de projet

Le projet respecte les exigences organisationnelles du cahier des charges :

- Gitflow strict : branches main, dev, feature/— aucun push direct sur main ou dev.
- Pull Requests obligatoires avec minimum 1 reviewer par PR.
- Commits explicites et historiques lisibles.
- Planning poker documenté dans docs/planning_poker.md avec échelle Fibonacci.
- Répartition des features (F1–F8) entre les membres de l'équipe.
- Chaque membre : au moins 1 PR ouverte, 1 PR reviewée, 1 feature en responsabilité.

8. Bilan, limites et améliorations

Bilan

Projet complet et fonctionnel. L'ensemble des livrables attendus a été produit : stack ELK opérationnelle, deux index documentés, 12 requêtes DSL, dashboard Kibana, moteur de recherche fonctionnel et documentation complète.

Limites

- Dataset hétérogène avec de nombreuses valeurs manquantes sur les champs financiers.
- Données manquantes non entièrement imputables (budget = 0 pour ~70 % des films).

Pistes d'amélioration

- Scoring avancé avec fonction_score sur popularité et vote_average.
- Comparaison de plusieurs analyzers (français, anglais, multilingue).
- Pagination avancée dans le moteur de recherche.

- Enrichissement des données via API TMDB.